



T.C.  
DOKUZ EYLÜL ÜNİVERSİTESİ  
FEN FAKÜLTESİ  
İSTATİSTİK BÖLÜMÜ

---

Üretim Planlamada Satın Alma Miktarlarının Tahmini: Zaman Serisi ve Makine  
Öğrenmesi Uygulamaları

---

Staj Raporu

---

Derya Porsuk

Eylül, 2025

# Özet

Bu staj çalışması, Fuga Mobilya'nın Üretim Planlama Departmanında gerçekleştirilmiştir. Çalışmanın temel amacı, satın alınan miktarların 2025 Temmuz ayı için tahmin edilmesi ve planlama süreçlerine katkı sağlanmasıdır.

İlk aşamada veriler Qlik Sense ve SQL yardımıyla düzenlenmiş ve analiz için uygun hale getirilmiştir. Daha sonra farklı yöntemler denenmiştir. Öncelikle segmentasyon yaklaşımı kullanılarak veriler gruplara ayrılmış ve her segment için ayrı tahmin modelleri oluşturulmuştur. Makine öğrenmesi yöntemlerinden XGBoost algoritması da bu süreçte uygulanmış ve segmentlere ayırma yöntemine kıyasla daha iyi sonuçlar vermiştir. Son olarak zaman serisi yöntemleri kullanılmış; Holt modeli ve ARIMA analizi ile serinin zamana bağlı yapısı değerlendirilmiştir.

Genel olarak çalışma boyunca farklı yöntemler uygulanmış ve karşılaştırılmıştır. Elde edilen bulgular, üretim planlamada veri temelli yaklaşımların kullanılabileceğini göstermiştir. Bu süreç, hem teorik bilgilerin uygulamaya aktarılması hem de analiz becerilerinin geliştirilmesi açısından önemli bir deneyim sağlamıştır.

**Anahtar kelimeler:** Özellik Mühendisliği, Zaman Serisi, Makine Öğrenmesi, Üretim Planlama

# İçindekiler

|                                                        |           |
|--------------------------------------------------------|-----------|
| <b>Bölüm 1: Giriş</b>                                  | <b>2</b>  |
| <b>Bölüm 2: Staj Sürecindeki Analiz ve Uygulamalar</b> | <b>3</b>  |
| 2.1 Veri Seti                                          | 3         |
| 2.2 Veri Analizi                                       | 4         |
| 2.2.1 Tanımlayıcı İstatistikler                        | 4         |
| 2.2.2 Segmentasyon Yaklaşımı ve Uygulanması            | 6         |
| 2.2.3 Özellik Mühendisliği                             | 9         |
| 2.2.4 XGBoost Modeli                                   | 9         |
| 2.2.5 Zaman Serisi Analizi                             | 11        |
| <b>Bölüm 3: Sonuç</b>                                  | <b>18</b> |
| <b>Kaynaklar</b>                                       | <b>19</b> |

# Şekil Listesi

|      |                                                    |    |
|------|----------------------------------------------------|----|
| 2.1  | Satın Alınan Miktar Dağılımı . . . . .             | 5  |
| 2.2  | Değişken Boxplot . . . . .                         | 5  |
| 2.3  | Segment Bazlı Tahmin Performansı Grafiği . . . . . | 7  |
| 2.4  | XGBoost Modeli Gerçek vs Tahmin . . . . .          | 11 |
| 2.5  | Zaman Serisi Grafiği . . . . .                     | 13 |
| 2.6  | Quadratic Model . . . . .                          | 13 |
| 2.7  | Lineer Model . . . . .                             | 13 |
| 2.8  | Double Exponential Smoothing . . . . .             | 14 |
| 2.9  | ACF Grafiği . . . . .                              | 15 |
| 2.10 | PACF Grafiği . . . . .                             | 15 |
| 2.11 | Artıkların ACF Grafiği . . . . .                   | 16 |
| 2.12 | Artıkların PACF Grafiği . . . . .                  | 16 |
| 2.13 | Tahmin Grafiği . . . . .                           | 17 |

# Tablo Listesi

|      |                                                                    |    |
|------|--------------------------------------------------------------------|----|
| 2.1  | Veri Setinde Yer Alan Değişkenler . . . . .                        | 3  |
| 2.2  | Veri Setinin Tanımlayıcı İstatistikleri . . . . .                  | 4  |
| 2.3  | Toplam Boş Değer Sayısı . . . . .                                  | 4  |
| 2.4  | Segment Bazlı Modelleme Yaklaşımları . . . . .                     | 6  |
| 2.5  | Segment Bazlı RMSE Değerleri . . . . .                             | 6  |
| 2.6  | Küçük Segment için Gerçek ve Tahmin Değerleri . . . . .            | 8  |
| 2.7  | Özellik Mühendisliği ile Oluşturulan Yeni Değişkenler . . . . .    | 9  |
| 2.8  | Modelin Performans Metrikleri . . . . .                            | 9  |
| 2.9  | Temmuz 2025 Dönemi Satın Alınan Miktar ve Tahmin Değerleri . . . . | 10 |
| 2.10 | Haftalar ve Toplam Satın Alınan Miktar (Ocak–Ağustos 2025) . . . . | 12 |
| 2.11 | Augmented Dickey–Fuller (ADF) Testi Sonuçları . . . . .            | 14 |
| 2.12 | Final Estimates of Parameters . . . . .                            | 15 |
| 2.13 | Model Summary . . . . .                                            | 15 |
| 2.14 | Modified Box–Pierce (Ljung–Box) Chi–Square Statistic . . . . .     | 16 |
| 2.15 | Güven Aralığı . . . . .                                            | 16 |

# Bölüm 1

## Giriş

Bu staj çalışması, Fuga Mobilya (2025)'nin Üretim Planlama Departmanında gerçekleştirilmiştir. Fuga Mobilya, mobilya sektöründe yenilikçi tasarımları ve geniş ürün yelpazesiyle öne çıkan bir markadır. Türkiye'nin yanı sıra 5 kıtada 9 ülkede 22 tane mağazası bulunan firma, hem yurt içinde hem de yurt dışında 30 yılı aşkın süredir geniş bir müşteri kitlesine hizmet vermektedir. Şirketin üretim planlama faaliyetleri, stok yönetimi ve satın alma kararlarının etkin biçimde yapılması açısından kritik bir rol üstlenmektedir. Çalışmada, Fuga Mobilya'nın üretim planlama süreçlerinde kullanılan veriler üzerinde çeşitli istatistiksel ve makine öğrenmesi yöntemleri uygulanmıştır. Ocak 2025 – Haziran 2025 dönemine ait veriler kullanılarak, Temmuz 2025 ayına ilişkin satın alma miktarlarının tahmin edilmesi hedeflenmiştir. Analiz sürecinde segmentasyon uygulaması, makine öğrenmesi algoritmalarından XGBoost ve zaman serisi yöntemleri adım adım uygulanmış ve elde edilen sonuçlar karşılaştırılmıştır.

Çalışmanın temel amacı, satın alma miktarlarının daha doğru tahmin edilmesi yoluyla üretim planlama sürecine katkı sağlamak ve karar vericilere veri temelli bir bakış açısı kazandırmaktır. Bu kapsamda farklı yöntemlerin performansları değerlendirilmiş, planlama süreçlerinde hangi yaklaşımların daha uygun olabileceğine yönelik çıkarımlar yapılmıştır.

## Bölüm 2

# Staj Sürecindeki Analiz ve Uygulamalar

Bu bölümde çalışmanın temel amacı ve kullanılan veri seti ayrıntılı olarak açıklanmıştır. Fuga Mobilya A.Ş.'nin üretim planlama departmanından elde edilen veriler üzerinde çeşitli analiz yöntemleri uygulanmıştır. Çalışmanın amacı, 2025 yılı Ocak–Haziran dönemine ait verileri kullanarak Temmuz ayı satın alma miktarını her bir malzeme kodu için tahmin etmektir.

Bu kapsamda önce veri setinin tanıtımı yapılmış, ardından farklı yöntemler kullanılarak analizler gerçekleştirilmiştir. Segmentasyon uygulaması, makine öğrenmesi (XGBoost) ve zaman serisi modelleri (Holt ve ARIMA) incelenmiş, sonuçlar karşılaştırılmalı olarak değerlendirilmiştir. Böylece, üretim planlama sürecinde hangi yöntemlerin daha başarılı sonuç verdiği ortaya konulmuştur.

### 2.1 Veri Seti

Çalışmada kullanılan veri seti, Fuga Mobilya'nın Üretim Planlama Departmanı'ndan alınmıştır. Veriler, Login sistemi üzerinden parçalar halinde elde edilip SQL yardımıyla tarih ve malzeme kodları kullanılarak birleştirilmiştir. Veri seti, 2025 yılı Ocak ve Temmuz ayları arasındaki dönemi kapsamaktadır ve aylık bazda düzenlenmiş olup 589 satırdan oluşmaktadır. Adar, İsmail (2012)

Tablo 2.1: Veri Setinde Yer Alan Değişkenler

| Değişken               | Açıklama                                                                 |
|------------------------|--------------------------------------------------------------------------|
| Malzeme Kodu           | Her bir ürün veya malzeme için tanımlanmış benzersiz kod                 |
| Ay                     | Gözlemin ait olduğu zaman dilimi (ör. 2025-03, 2025-04)                  |
| Satın Alınan Miktar    | İlgili ayda tedarik edilen ürün miktarı                                  |
| Stok Çıkış Miktarı     | Depodan çıkan, kullanılan veya satılan miktar                            |
| Toplam Satış Miktarı   | İlgili aya ait toplam satış hacmi                                        |
| Üç Aylık Satış Miktarı | Mevsimsellik etkilerini yansıtan üç aylık hareketli toplam satış miktarı |

## 2.2 Veri Analizi

Çalışmada bağımlı değişken olarak “Satın Alınan Miktar” ele alınmıştır. Modelleme sürecinde Ocak-Haziran süreci eğitim seti, Temmuz ise test seti olarak ayrılmış ve tahmin modellerinin performansı bu test verileri üzerinde değerlendirilmiştir. Analiz süreci ise PythonGoogle Colab (2025) ve Minitab, LLC (2025) ortamlarında gerçekleştirilmiştir.

### 2.2.1 Tanımlayıcı İstatistikler

Tablo 2.2: Veri Setinin Tanımlayıcı İstatistikleri

| Değişken               | count | mean      | std       | min | 25% | 50%  | 75%  | max    |
|------------------------|-------|-----------|-----------|-----|-----|------|------|--------|
| Satın Alınan Miktar    | 589.0 | 45.908139 | 95.481389 | 1.0 | 7.0 | 15.0 | 40.0 | 1010.0 |
| Stok Çıkış Miktarı     | 589.0 | 26.421263 | 60.180654 | 0.0 | 2.0 | 6.0  | 20.0 | 550.0  |
| Toplam Satış Miktarı   | 589.0 | 17.416595 | 33.081003 | 0.0 | 4.0 | 8.0  | 12.0 | 322.0  |
| Üç Aylık Satış Miktarı | 589.0 | 35.617997 | 81.612472 | 0.0 | 2.0 | 8.0  | 24.0 | 625.0  |

Veri setinin tanımlayıcı istatistikleri incelendiğinde, satın alınan miktar değişkeninin ortalama 45.9 olmasına rağmen maksimum değer 1010 olduğu görülmektedir. Bu durum, veri setinde uç değerlerin bulunduğunu göstermektedir. Benzer şekilde stok çıkış miktarı ortalama 26.4 iken maksimum 550’ye ulaşmakta, toplam satış miktarı ortalama 17.4 olmasına rağmen 322’ye kadar çıkmaktadır. Üç aylık satış miktarının ortalaması 35.6, maksimumu ise 625’tir. Çeyrekler incelendiğinde değişkenlerin büyük bölümünün düşük değerlere sahip olduğu, ancak az sayıda gözlemde çok yüksek değerler bulunduğu anlaşılmaktadır. Bu bulgular, veri setinde dengesizlik ve uç değerlerin var olduğunu gösterir.


### Eksik Değer Analizi

Tablo 2.3: Toplam Boş Değer Sayısı

| Değişken                       | Boş Değer Sayısı |
|--------------------------------|------------------|
| Malzeme Kodu                   | 0                |
| Ay                             | 0                |
| Satın Alınan Miktar            | 0                |
| Stok Çıkış Miktarı             | 0                |
| Toplam Satış Miktarı           | 0                |
| Üç Aylık Satış Miktarı         | 0                |
| dtype                          | int64            |
| <b>Toplam boş değer sayısı</b> | <b>0</b>         |

Veri setinde öncelikle eksik değer analizi yapılmıştır. Sonuç olarak veri setinde herhangi bir eksik değer bulunmamıştır.


## Histogram



Şekil 2.1: Satın Alınan Miktar Dağılımı

Satın alınan miktarların dağılımı incelendiğinde, gözlemlerin büyük bölümünün düşük değerlerde toplandığı, ancak az sayıda çok yüksek değer bulunduğundan görülmektedir. Histogram, dağılımın sağa çarpık olduğunu ve veri setinde uç değer bulunduğunu göstermektedir.

## Boxplot



Şekil 2.2: Değişken Boxplot

Her bir değişken için Boxplot grafiği incelendiğinde ise Satın alınan miktar değişkeni 1000'e kadar ulaşan gözlemler içerirken, stok çıkış miktarı 500'ün üzerine çıkmaktadır. Toplam satış miktarında 300'ün üzerinde, üç aylık satış miktarında ise 600'ün üzerinde uç gözlemler yer almaktadır. Bu bulgular, veri setinin dengesiz dağılıma sahip olduğunu ve uç değerlerin modelleme sürecinde dikkate alınması gerektiğini ortaya koymaktadır.

### 2.2.2 Segmentasyon Yaklaşımı ve Uygulanması

Ürün grupları farklı dağılımlara sahip olduğu için tek model yeterli sonuç vermemektedir. Segmentleme sayesinde her grup için uygun model seçilmiştir. Böylece hem iş mantığına uyum sağlanmış hem de tahmin hataları azaltılmıştır.

Satın alınan miktara göre gözlemler **küçük**, **orta**, **büyük-1** ve **büyük-2** segmentlerine ayrılmıştır. Bu yöntem, her segmentin farklı dinamiklerini yakalayarak modelin doğruluğunu artırmak için tercih edilmiştir.

Tablo 2.4: Segment Bazlı Modelleme Yaklaşımları


| Segment         | Uygulanan Yöntem / Açıklama                                                                                                                                    |
|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Küçük Segment   | Doğrusal regresyon modeli kullanılmış, tahmin değerleri <b>clipping yöntemi</b> ile 0-50 aralığına sınırlandırılmıştır.                                        |
| Orta Segment    | Doğrusal regresyon modeli uygulanmıştır.                                                                                                                       |
| Büyük-1 Segment | <b>Log dönüşümü</b> ile uç değerlerin etkisi azaltılmış, ardından <b>XGBoost modeli</b> kullanılmıştır.                                                        |
| Büyük-2 Segment | <b>Kural tabanlı yöntem</b> ile <b>XGBoost</b> sonuçları birleştirilmiştir.<br>%70 kural ve %30 XGBoost ağırlıklı <b>ensemble yaklaşımı</b> tercih edilmiştir. |

### Sonuçların Derlenmesi ve Değerlendirilmesi

Segment bazlı RMSE değerleri incelendiğinde, küçük segmentte hata oranının oldukça düşük (13.18) olduğu, orta segmentte ise 23.75 olduğu görülmektedir. Büyük-1 segmentinde hata 53.18 iken, en yüksek hata büyük-2 segmentinde (113.86) gözlemlenmiştir. Bu durum, yüksek hacimli ürünlerde tahminlemenin daha zor olduğunu ve hata payının arttığını göstermektedir.

Tablo 2.5: Segment Bazlı RMSE Değerleri

| Segment         | RMSE Değeri |
|-----------------|-------------|
| Büyük-1 Segment | 53.185215   |
| Büyük-2 Segment | 113.862912  |
| Küçük Segment   | 13.183052   |
| Orta Segment    | 23.751631   |



Şekil 2.3: Segment Bazlı Tahmin Performansı Grafiği

### Gerçek ve Tahmin Değerlerinin Karşılaştırılması

Segment bazlı modelleme sonucunda elde edilen tahminler, gerçek değerler ile karşılaştırılmıştır. Aşağıdaki tabloda Temmuz ayına ait ilk 30 gözlem için Gerçek ve Tahmin değerleri verilmiştir.

Tablo 2.6: Küçük Segment için Gerçek ve Tahmin Değerleri

| Segment | Malzeme Kodu | Gerçek Değer | Tahmin Değeri |
|---------|--------------|--------------|---------------|
| küçük   | A100308.90   | 5            | 12.743684     |
| küçük   | A100593.00   | 20           | 41.175011     |
| küçük   | A100593.42   | 26           | 16.799749     |
| küçük   | A110005.20   | 20           | 34.213356     |
| küçük   | A110005.50   | 40           | 24.497693     |
| küçük   | A110021.42   | 40           | 47.693963     |
| küçük   | A110021.90   | 8            | 9.079432      |
| küçük   | A110027.60   | 12           | 12.380895     |
| küçük   | A110027.90   | 16           | 16.878936     |
| küçük   | A110032.00   | 3            | 13.306365     |
| küçük   | A110032.50   | 12           | 11.701464     |
| küçük   | A110033.00   | 4            | 12.078956     |
| küçük   | A110041.90   | 10           | 15.332222     |
| küçük   | A110041.92   | 8            | 15.819265     |
| küçük   | A110051.00   | 32           | 32.828483     |
| küçük   | A110051.90   | 10           | 40.476523     |
| küçük   | A110051.50   | 12           | 17.707237     |
| küçük   | A110060.00   | 12           | 31.221607     |
| küçük   | A110060.50   | 15           | 15.818430     |
| küçük   | A110074.50   | 5            | 15.565996     |
| küçük   | A110074.50   | 8            | 15.332222     |
| küçük   | A110079.90   | 20           | 20.838082     |
| küçük   | A110081.90   | 8            | 15.197256     |
| küçük   | A110120.00   | 40           | 12.561316     |
| küçük   | A110120.50   | 12           | 11.701464     |
| küçük   | A110134.92   | 8            | 15.332222     |
| küçük   | A110143.00   | 14           | 14.710925     |

Tablo incelendiğinde modelin çoğu gözlemde kabul edilebilir seviyede tahmin yaptığı, ancak bazı gözlemlerde sapmaların bulunduğu görülmektedir. Bu nedenle tahmin performansını geliştirmek adına analize özellik mühendisliği yöntemi ile devam edilmiştir.

### 2.2.3 Özellik Mühendisliği

Ham veri setinde stok çıkış miktarı, üç aylık satış miktarı, toplam satış miktarı ve satın alınan miktar gibi temel değişkenler yer almaktadır. Ancak bu değişkenler doğrudan modele verildiğinde, modelin değişkenler arasındaki karmaşık ilişkileri yakalaması zorlaşmaktadır. Özellikle stok ve satış arasındaki dengeyi, talep ve arz farklarını ya da yüksek hacimli ürünlerin farklı davranışlarını bu değişkenler tek başına yeterince açıklayamamaktadır.

Bu nedenle veri üzerinde özellik mühendisliği uygulanmış ve mevcut değişkenlerden yeni türev değişkenler üretilmiştir. Oluşturulan oran ve fark değişkenleri stok-satış arasındaki dengesizlikleri yansıtırken, logaritmik dönüşümler uç değerlerin etkisini azaltmıştır. Ayrıca büyük hacimli ürünleri belirtmek amacıyla ikili (binary) bir değişken tanımlanmıştır. Bu adımlar sayesinde modelin öğrenme gücü artırılmış ve tahmin performansında iyileşme sağlanması hedeflenmiştir. Parmaksız, H. and Özer, Z. (2024)

### Özellik Mühendisliği İle Oluşturulan Yeni Değişkenler

Tablo 2.7: Özellik Mühendisliği ile Oluşturulan Yeni Değişkenler

| Değişken Adı | Tanım / Formül                      | Açıklama                                                                 |
|--------------|-------------------------------------|--------------------------------------------------------------------------|
| Oran1        | Stok Çıkış / 3 Aylık Satış          | Satış hacmine göre stok çıkış oranını gösterir.                          |
| Oran2        | Stok Çıkış / Toplam Satış           | Toplam satışa göre stok çıkış oranını temsil eder.                       |
| Oran3        | Satın Alınan Miktar / 3 Aylık Satış | Satın alma miktarının satış hacmine oranını gösterir.                    |
| Fark1        | 3 Aylık Satış – Stok Çıkış          | Gerçekleşen satış miktarı ile stok çıkışı arasındaki farkı ölçer.        |
| Fark2        | Toplam Satış – Satın Alınan Miktar  | Satın alma ile satış miktarı arasındaki farkı gösterir.                  |
| log_ÜçAylık  | $\log(\text{Üç Aylık Satış} + 1)$   | Uç değerlerin etkisini azaltmak için log dönüşümü uygulanmıştır.         |
| log_Toplam   | $\log(\text{Toplam Satış} + 1)$     | Toplam satış verisinde yüksek değerlerin baskısını azaltır.              |
| Is_Large     | $(\text{Üç Aylık Satış} > 200)$     | 3 aylık satış 200’ü aştığında 1, aksi durumda 0 atanır (ikili değişken). |

Özellik mühendisliği adımıyla oluşturulan yeni değişkenler veri setine eklenmiştir. Analize yeni oluşturulan değişkenler ve XGBoost (2020) modeli ile devam edilmiştir.

### 2.2.4 XGBoost Modeli

Bu bölümde özellik mühendisliği sonrası elde edilen değişkenler kullanılarak XGBoost modeli kurulmuştur. Model Ocak–Haziran verileriyle eğitilmiş ve Temmuz verisi üzerinde test edilmiştir. Performans değerlendirmesinde RMSE ve  $R^2$  değerleri hesaplanmıştır. Ayrıca modelin doğruluğunu göstermek amacıyla ilk 20 gözlem için Gerçek ve Tahmin değerleri tablo halinde sunulmuştur. Sonuçlar, özellik mühendisliği sayesinde model performansının belirgin şekilde iyileştiğini göstermektedir.

Tablo 2.8: Modelin Performans Metrikleri

| Metrik | Değer              |
|--------|--------------------|
| RMSE   | 17.686902147305485 |
| $R^2$  | 0.9651288390159607 |

Temmuz ayı test verisi üzerinde modelin RMSE değeri 17.68,  $R^2$  değeri ise 0.96 olarak bulunmuştur. Bu sonuçlar, modelin hata oranının düşük, açıklama gücünün ise oldukça yüksek olduğunu göstermektedir. Özellik mühendisliğinin model performansına önemli katkı sağladığı açıkça görülmektedir.


### Gerçek Değerler ve Tahmin Değerleri Karşılaştırması

Aşağıdaki tabloda Temmuz ayı satın alma miktarı gerçek değerleri ve tahmin değerleri karşılaştırmalı olarak sunulmuştur. Tablo incelendiğinde modelin genel olarak tutarlı sonuçlar verdiği görülmektedir.

Tablo 2.9: Temmuz 2025 Dönemi Satın Alınan Miktar ve Tahmin Değerleri

| Index | Malzeme Kodu | Ay         | Satın Alınan Miktar | Tahmin Değeri |
|-------|--------------|------------|---------------------|---------------|
| 6     | A100042.50   | 2025-07-01 | 357                 | 444.273407    |
| 14    | A100308.90   | 2025-07-01 | 5                   | 5.641361      |
| 17    | A100593.00   | 2025-07-01 | 20                  | 19.995332     |
| 18    | A100593.42   | 2025-07-01 | 20                  | 19.990629     |
| 33    | A110005.50   | 2025-07-01 | 20                  | 19.0994650    |
| 36    | A110021.42   | 2025-07-01 | 20                  | 19.990875     |
| 43    | A110010.90   | 2025-07-01 | 76                  | 76.001282     |
| 45    | A110010.12   | 2025-07-01 | 61                  | 60.992371     |
| 49    | A110021.42   | 2025-07-01 | 168                 | 168.002670    |
| 56    | A110032.00   | 2025-07-01 | 40                  | 39.969212     |
| 60    | A110033.00   | 2025-07-01 | 128                 | 101.666504    |
| 68    | A110041.92   | 2025-07-01 | 615                 | 614.990662    |
| 75    | A110051.00   | 2025-07-01 | 90                  | 90.022362     |
| 78    | A110051.90   | 2025-07-01 | 2                   | 7.995037      |
| 81    | A110027.50   | 2025-07-01 | 250                 | 176.289948    |
| 88    | A110032.50   | 2025-07-01 | 63                  | 62.976166     |
| 91    | A110033.00   | 2025-07-01 | 59                  | 59.028431     |
| 101   | A110041.92   | 2025-07-01 | 6                   | 7.996479      |
| 102   | A110051.00   | 2025-07-01 | 5                   | 4.998368      |
| 107   | A110060.00   | 2025-07-01 | 3                   | 3.005674      |
| 111   | A110060.50   | 2025-07-01 | 3                   | 3.016940      |

## XGBoost Modeli Gerçek vs Tahmin Grafik Gösterimi



Şekil 2.4: XGBoost Modeli Gerçek vs Tahmin

XGBoost modeli ile elde edilen tahminler, gerçek değerlerle oldukça yüksek bir uyum göstermektedir. Grafik incelendiğinde noktaların büyük çoğunluğunun mükemmel tahmin çizgisine yakın olduğu görülmektedir. Bu durum, modelin satın alınan miktarı açıklamada yüksek doğruluk sağladığını ve daha önce segmentasyon yöntemi ile ulaşılamayan güçlü bir performans ortaya koyduğunu göstermektedir. Şekeroğlu, G. and Acıcılar, A. M. (2025)

### 2.2.5 Zaman Serisi Analizi

Her bir malzeme kodu için ayrı ayrı zaman serisi analizi yapılabilecek kadar uzun veriye sahip olmadığımızdan, tüm ürünler için aylık toplam satın alma miktarı serisi üzerinden modelleme denenmiştir. Ancak elimizde yalnızca 8 aylık veri bulunduğundan, aylık bazda zaman serisi analizi için veri uzunluğu yetersiz kalmıştır. Bu nedenle analizler haftalık bazda tekrarlanmış ve haftalık toplam satın alma miktarı serisi oluşturulmuştur. Haftalık bazda yapılan analizlerin, hem gözlem sayısını artırması hem de serinin yapısını daha iyi yansıtması nedeniyle daha uygun olacağına karar verilmiştir. Erden, C. (2018)


Bu kapsamda, 1 Ocak – 10 Ağustos 2025 tarihleri arasındaki veriler kullanılarak haftalık zaman serisi oluşturulmuş ve analiz adımları bu veri seti üzerinden gerçekleştirilmiştir. Analizin amacı, önümüzdeki 4 haftanın satın alma miktarlarını tahmin etmektir. Çalışma Minitab ortamında gerçekleştirilmiştir.

#### Zaman Serisi Analizi İçin Haftalık Veri Seti

Zaman serisi analizi kapsamında, üretim planlama departmanından alınan ham veri SQL ortamında haftalık bazda yeniden düzenlenmiş ve analiz için uygun formata getirilmiştir. Toplam 32 haftadan oluşmaktadır.

Tablo 2.10: Haftalar ve Toplam Satın Alınan Miktar (Ocak–Ağustos 2025)


| <b>Haftalar</b> | <b>Toplam Satın Alınan Miktar</b> |
|-----------------|-----------------------------------|
| 2025-01-05      | 67                                |
| 2025-01-12      | 449                               |
| 2025-01-19      | 126                               |
| 2025-01-26      | 125                               |
| 2025-02-02      | 764                               |
| 2025-02-09      | 123                               |
| 2025-02-16      | 785                               |
| 2025-02-23      | 488                               |
| 2025-03-02      | 1221                              |
| 2025-03-09      | 1521                              |
| 2025-03-16      | 1239                              |
| 2025-03-23      | 1744                              |
| 2025-03-30      | 872                               |
| 2025-04-06      | 100                               |
| 2025-04-13      | 432                               |
| 2025-04-20      | 1332                              |
| 2025-04-27      | 796                               |
| 2025-05-04      | 630                               |
| 2025-05-11      | 408                               |
| 2025-05-18      | 1193                              |
| 2025-05-25      | 641                               |
| 2025-06-01      | 1236                              |
| 2025-06-08      | 421                               |
| 2025-06-15      | 2089                              |
| 2025-06-22      | 3038                              |
| 2025-06-29      | 767                               |
| 2025-07-06      | 913                               |
| 2025-07-13      | 666                               |
| 2025-07-20      | 1216                              |
| 2025-07-27      | 231                               |
| 2025-08-03      | 722                               |
| 2025-08-10      | 458                               |




Şekil 2.5: Zaman Serisi Grafiği

Grafık, haftalık satın alınan miktarın dalgalı bir seyir izlediğini göstermektedir. Özellikle 25. haftada çok yüksek bir değer gözlenmiştir. Genel olarak belirgin bir trend yapısı yoktur, dalgalanmalar öne çıkmaktadır.

### Trend Analizi



Şekil 2.6: Quadratic Model




Şekil 2.7: Lineer Model

Lineer ve Quadratic trend modelleri denenmiş, ancak hata değerlerinin yüksek olması ve verinin dalgalı yapısı nedeniyle daha uygun yöntemlere geçilmiştir.

### Holt – Double Exponential Smoothing

Verimiz haftalık olsa da elimizde sadece birkaç aylık veri olduğundan, belirgin bir mevsimsel yapı gözlemlenmemektedir. Bu yüzden Winters modeli uygulanmamış, Holt modeli tercih edilmiştir.



Şekil 2.8: Double Exponential Smoothing

Şekil incelendiğinde, Double Exponential Smoothing yöntemi ile elde edilen tahminlerin, serinin genel eğilimini yakalayamadığı ani dalgalanmaları yeterince yansıtamadığı görülmektedir. MAPE, MAD ve MSD hata ölçütleri oldukça yüksek olup modelin doğruluğu sınırlı kalmıştır.


### Durağanlık Testi (ADF)

Tablo 2.11: Augmented Dickey-Fuller (ADF) Testi Sonuçları


| İstatistik                       | Değer / Açıklama                                                      |
|----------------------------------|-----------------------------------------------------------------------|
| Null Hypothesis ( $H_0$ )        | Veri durağan değildir (non-stationary).                               |
| Alternative Hypothesis ( $H_1$ ) | Veri durağandır (stationary).                                         |
| Test Statistic                   | -5.45127                                                              |
| P-Value                          | 0.000                                                                 |
| Kritik Değer (5%)                | -2.96053                                                              |
| Karar                            | Test statistic $\leq$ kritik değer $\Rightarrow H_0$ reddedilir.      |
| Sonuç                            | Veri durağan görünmektedir, fark alma (differencing) gerekmemektedir. |

ADF testinde p-değeri 0.05'ten küçük (0.000) bulunmuştur. Bu da serinin durağan olduğunu göstermektedir.

### ACF ve PACF Grafikleri



Şekil 2.9: ACF Grafiği



Şekil 2.10: PACF Grafiği

ACF ve PACF grafikleri incelendiğinde, otokorelasyonların ilk gecikmelerden sonra hızla azaldığı ve belirgin bir otokorelasyon yapısının olmadığı görülmektedir. Bu durum serinin durağan olduğunu desteklemektedir.

### ARIMA

Farklı ARIMA(p,q) modelleri AIC, AICc ve BIC kriterlerine göre karşılaştırılmıştır ve en uygun model olarak ARIMA(1,0,0) belirlenmiştir.

Tablo 2.12: Final Estimates of Parameters

| Type     | Coef  | SE Coef | T-Value | P-Value |
|----------|-------|---------|---------|---------|
| AR(1)    | 0.009 | 0.184   | 0.05    | 0.959   |
| Constant | 837   | 112     | 7.50    | 0.000   |
| Mean     | 845   | 113     |         |         |

Seçilen modelde sabit terim anlamlı çıkmış, AR katsayısı ise istatistiksel olarak anlamlı bulunmamıştır.


Tablo 2.13: Model Summary

| Özellik | Değer    |
|---------|----------|
| DF      | 30       |
| SS      | 11951386 |
| MS      | 398380   |
| MSD     | 373481   |
| AICc    | 508.315  |
| AIC     | 507.457  |
| BIC     | 511.855  |


Tablo 2.14: Modified Box–Pierce (Ljung–Box) Chi–Square Statistic

| Lag        | 12    | 24    | 36 | 48 |
|------------|-------|-------|----|----|
| Chi–Square | 7.26  | 18.63 | *  | *  |
| DF         | 10    | 22    | *  | *  |
| P–Value    | 0.701 | 0.668 | *  | *  |

Ljung-Box testi sonucunda p-değerleri 0.05'ten büyük çıkmıştır. Bu durum artıkların otokorelasyon içermediğini ve modelin uygun olduğunu göstermektedir.



Şekil 2.11: Artıkların ACF Grafiği




Şekil 2.12: Artıkların PACF Grafiği

Artıkların ACF ve PACF grafikleri incelendiğinde, anlamlı bir otokorelasyon yapısı görülmemektedir. Bu durum, model artıklarının rassal dağıldığını ve modelin varsayımları sağladığını göstermektedir.

Tablo 2.15: Güven Aralığı

| Time Period | Forecast | SE Forecast | Lower (95%) | Upper (95%) | Actual |
|-------------|----------|-------------|-------------|-------------|--------|
| 33          | 840.988  | 631.173     | -396.361    | 2078.34     |        |
| 34          | 844.617  | 631.201     | -392.787    | 2082.02     |        |
| 35          | 844.651  | 631.201     | -392.753    | 2082.06     |        |

ARIMA modeli ile yapılan tahmin sonuçlarına göre 33., 34. ve 35. dönemler için öngörülen satın alma miktarları yaklaşık 840–845 birim aralığında gerçekleşmiştir. Ancak tahminlere ait güven aralıklarının oldukça geniş olduğu görülmektedir. Bu durum, modelin ileriye dönük tahminlerde yüksek belirsizlik içerdiğini ve güvenilirliğinin sınırlı olduğunu göstermektedir.



Şekil 2.13: Tahmin Grafiği

Grafikte, serinin geçmişte oldukça dalgalı bir yapıya sahip olduğu, özellikle bazı haftalarda ani artışların olduğu görülmektedir. ARIMA modeliyle elde edilen tahminler ise serinin oynaklığını ve ani değişimlerini yansıtamamıştır. Ayrıca tahminlerin güven aralıkları çok geniş çıkmış, bu da belirsizliğin yüksek olduğunu göstermektedir.

## Bölüm 3

### Sonuç

Bu staj çalışmasının temel amacı, Fuga Mobilya'nın üretim planlama süreçlerinde her malzeme için Temmuz ayı satın alınan miktarlarının doğru bir şekilde tahmin edilmesi ve veri temelli bir katkı sunmaktır. Çalışmada, segmentasyon uygulaması, özellik mühendisliği, XGBoost algoritması ve zaman serisi yöntemleri (Holt ve ARIMA) uygulanmış ve elde edilen sonuçlar karşılaştırılmıştır.

Analizler göstermiştir ki, segmentasyon yaklaşımı ile model performansı uç değerler için sınırlı kalırken, en başarılı sonuçlar XGBoost algoritması ile elde edilmiştir. Zaman serisi yöntemleri ise serinin kısa uzunluğu ve dalgalı yapısı nedeniyle sınırlı ve zayıf öngörüler sağlamıştır. Bu bulgular, üretim planlama departmanında makine öğrenmesi yöntemlerinin güçlü bir alternatif sunduğunu, fakat verinin yapısına uygun model seçiminin kritik olduğunu ortaya koymuştur.

Staj süreci, teorik olarak öğrenilen istatistiksel ve makine öğrenmesi yöntemlerinin gerçek iş ortamında ve gerçek hayat verisinde uygulanmasına olanak tanımış ve veri analizi becerilerimi geliştirmiştir. Özellikle SQL, Python ve Qlik Sense kullanımıyla veri hazırlama, işleme ve görselleştirme konularında önemli deneyimler kazanılmıştır. Bunun yanında, takım çalışması, iş disiplinine uyum ve analitik düşünme becerilerinin pekişmesi, mesleki gelişimime ve kişisel gelişimime büyük katkı sağlamıştır.

Fuga Mobilya şirketi açısından ise, gerçekleştirilen analizler üretim planlama departmanına sunulmuştur. Satın alma miktarlarının tahminine yönelik alternatif yöntemler veri temelli karar verme sürecine katkı sağlamıştır. Böylelikle, stok yönetimi ve malzeme planlamasında daha etkin ve farklı açılardan geliştirilmesine destek olabilecek bulgular elde edilmiştir.

# Kaynaklar

- Adar, İsmail (2012). *SQL Server 2012: Programlama ve Yönetim*. İstanbul: Pusula Yayıncılık, 2 ed.
- Erden, C. (2018). Zaman serilerinde trend analizi [video].  
URL <https://www.youtube.com/watch?v=ONuGjH3i2L8>
- Fuga Mobilya (2025). Fuga mobilya.  
URL <https://www.fugamobilya.com>
- Google Colab (2025). Google colaboratory – python Çalışma ortamı.  
URL <https://colab.research.google.com>
- Minitab, LLC (2025). *Minitab Statistical Software*. Minitab, LLC, State College, PA, USA.
- Parmaksız, H. and Özer, Z. (2024). Gelişmiş Özellik mühendisliği ve makine Öğrenimi ile deprem tahmini. *Rahva Teknik ve Sosyal Araştırmalar Dergisi*, 4(2), 11–26.
- XGBoost (2020). Xgboost nasıl Çalışır? neden İyi performans gösterir?  
URL <https://veribilimiokulu.com/xgboost-nasil-calisir/>
- Şekeroğlu, G. and Acıcılar, A. M. (2025). Xgboost kullanılarak halka arzlarda kısa vadeli fiyat tahmini: Bist teknoloji sektörü Örneği. *Ekonomi Politika ve Finans Araştırmaları Dergisi*, 10(2), 549–567.

# Ek-1

## Python Kodları

```
# Gerekli Kütüphaneler
import pandas as pd
import numpy as np
import pickle
from sklearn.linear_model import LinearRegression
from xgboost import XGBRegressor
from sklearn.metrics import mean_squared_error

# Segmentasyon fonksiyonu
def segment(y):
    if y < 50:
        return "küçük"
    elif y < 150:
        return "orta"
    elif y <= 300:
        return "büyük-1"
    else:
        return "büyük-2"

# Veri yükleme ve ön işleme
df = pd.read_excel("SON (!).xlsx")
df = df.fillna(0)
df["Ay"] = pd.to_datetime(df["Ay"])

train = df[df["Ay"].dt.month < 7].copy()    # Ocak-Haziran
temmuz = df[df["Ay"].dt.month == 7].copy()

train["segment"] = train["Satın Alınan Miktar"].apply(segment)
temmuz["segment"] = temmuz["Satın Alınan Miktar"].apply(segment)

# Özellik mühendisliği
df_fe = df.copy()
df_fe["Oran1"] = df_fe["Stok Çıkış Miktarı"] / (df_fe["Üç Aylık Satış Miktarı"] + 1)
df_fe["Oran2"] = df_fe["Stok Çıkış Miktarı"] / (df_fe["Toplam Satış Miktarı"] + 1)
df_fe["Oran3"] = df_fe["Satın Alınan Miktar"] / (df_fe["Üç Aylık Satış Miktarı"] + 1)

df_fe["Fark1"] = df_fe["Üç Aylık Satış Miktarı"] - df_fe["Stok Çıkış Miktarı"]
df_fe["Fark2"] = df_fe["Toplam Satış Miktarı"] - df_fe["Satın Alınan Miktar"]

df_fe["log_ÜçAylık"] = np.log1p(df_fe["Üç Aylık Satış Miktarı"])
```

```
df_fe["log_Toplam"] = np.log1p(df_fe["Toplam Satış Miktarı"])

df_fe["Is_Large"] = (df_fe["Üç Aylık Satış Miktarı"] > 200).astype(int)

train = df[df["Ay"].dt.month < 7].copy()
temmuz = df[df["Ay"].dt.month == 7].copy()

# Model kurma
xgb = XGBRegressor(n_estimators=500, learning_rate=0.1, max_depth=6, random_state=42)
xgb.fit(X_train, y_train)

y_pred = xgb.predict(X_test)

# Lineer Regresyon modelleri
lr_k = LinearRegression()
lr_k.fit(X_k, y_k)
y_pred = lr_k.predict(X_test)
y_pred = np.clip(y_pred, 0, 50)

lr_o = LinearRegression()
lr_o.fit(X_o, y_o)
y_pred = lr_o.predict(X_test)

# XGBoost modelleri
y_b1 = np.log1p(train_b1["Satın Alınan Miktar"])
xgb_b1 = XGBRegressor(...)
xgb_b1.fit(X_b1, y_b1)

y_pred_log = xgb_b1.predict(X_test)
y_pred = np.expm1(y_pred_log)

y_pred_xgb = np.expm1(xgb_b2.predict(X_test))
y_pred_rule = (test_b2["Üç Aylık Satış Miktarı"] / 3) * 3
y_pred = 0.7 * y_pred_rule + 0.3 * y_pred_xgb

# Sonuçlar ve hata hesabı
final_results = pd.DataFrame(results, columns=["Segment", "Malzeme Kodu", "Gerçek", "Tahmin"])

segment_rmse = final_results.groupby("Segment").apply(
    lambda x: np.sqrt(mean_squared_error(x["Gerçek"], x["Tahmin"]))
)
```